



Toward Ever-Evolution Network Threats: A Hierarchical Federated Class-Incremental Learning Approach for Network Intrusion Detection in IIoT


NT204.Q22.ANTT - Nhóm 15
GVHD: Đỗ Hoàng Hiến



THÀNH VIÊN NHÓM 15

23521343	Nguyễn Ngọc Sáng
23521817	Tổng Xuân Vũ
23521048	Nguyễn Phương Nguyên

MỤC LỤC CHÍNH



01

VẤN ĐỀ BÀI BÁO

02

PHƯƠNG PHÁP THỰC HIỆN

03

THỰC NGHIỆM DATASET

04

TÀI LIỆU THAM KHẢO



Vấn đề bài báo

- Bối cảnh: hệ thống IDPS còn nhiều thiếu sót, , các phương pháp NID truyền thống như dựa trên signature-based hay rule-based đang ngày càng kém hiệu quả và thiếu khả năng mở rộng.
- Thách thức chính:
 - Các cuộc tấn công mạng mới xuất hiện liên tục khiến các hệ thống phát hiện xâm nhập (NID) truyền thống bị lỗi thời.
 - Quyền riêng tư dữ liệu của các dữ liệu nhạy cảm, các thiết bị IIoT có hạn chế về tài nguyên tính toán.
- Giải pháp: Xây dựng hệ thống NIDS trong môi trường IoT bằng cách
 - Kết hợp mô hình liên kết phân tầng (Federated Learning) để bảo mật dữ liệu và phương pháp học tăng cường (Class-Incremental Learning) để đối phó với các mối đe dọa luôn thay đổi.
 - Đề xuất chiến lược WTO cân bằng giữa yêu cầu phát hiện xâm nhập và giới hạn tài nguyên thiết bị IIoT, điều chỉnh động tốc độ truyền.

Cơ sở lý thuyết

- **Phát hiện xâm nhập mạng (NID)**

- NID là cơ chế bảo mật được thiết kế để giám sát và phân tích lưu lượng mạng nhằm phát hiện các dấu hiệu tấn công độc hại hoặc vi phạm chính sách bảo mật.
- Khó khăn khi áp dụng vào các kịch bản IIoT phức tạp — đặc biệt trong việc đáp ứng yêu cầu bảo mật dữ liệu và giải quyết nhu cầu phòng thủ liên tục, động.

- **Federated Learning trong NID**

- FL cho phép huấn luyện mô hình cộng tác giữa các edge server trong khi bảo vệ dữ liệu riêng tư. Cách tiếp cận này giảm tải cho cloud trung tâm và nâng cao hiệu quả hệ thống.
- Còn thiếu các chiến lược phòng thủ bảo mật động để thích nghi với bối cảnh đe dọa không ngừng thay đổi với các loại tấn công mới và đa dạng.


- **Class-Incremental Learning trong NID**

- Trong môi trường IIoT, bối cảnh đe dọa liên tục tiến hóa với các kỹ thuật tấn công mới và tinh vi đòi hỏi phải áp dụng các chiến lược bảo mật động. CIL cho phép hệ thống IDS điều chỉnh và học khi các lớp mới đe dọa mới xuất hiện, đảm bảo mô hình luôn phù hợp theo thời gian.

Phương pháp thực hiện

- **HFIN (Hierarchical Federated Incremental Learning):** Kết hợp mô hình liên kết phân tầng (Federated Learning) để bảo mật dữ liệu và phương pháp học tăng cường (Class-Incremental Learning)
- Sử dụng mô hình 3 lớp:
 - **Cloud Server:** Quản lý và phổ biến các chính sách bảo mật toàn cầu, đồng thời tổng hợp các mô hình cục bộ từ các Edge server để tạo ra mô hình chung mà không làm rò rỉ dữ liệu.
 - **Edge Servers:** Đóng vai trò lớp trung gian, thu thập và xử lý luồng mạng từ các thiết bị client, trực tiếp huấn luyện mô hình cục bộ do các thiết bị client hạn chế về tài nguyên tính toán.
 - **Client:** Thu thập các luồng mạng và truyền dữ liệu liên quan đến bảo mật về các Edge server để phân tích.
- Tối ưu hóa Truyền dẫn **WTO**:
 - Tính toán trọng số: Mỗi loại tấn công được gán một trọng số dựa trên tỉ lệ giữa độ chính xác và kích thước mẫu thu thập được.
 - Hàng đợi ưu tiên: Hệ thống sử dụng hàng đợi ưu tiên dựa trên tích của trọng số và tốc độ truyền dẫn để quyết định thiết bị nào được phép gửi dữ liệu trước

Mô hình triển khai



Dataset

- NF-UQ-NIDS-v2: ~75.9 triệu bản ghi, tích hợp từ 4 nguồn khác nhau với 20 loại tấn công: DDoS, DoS, Scanning, Reconnaissance, XSS, Password, Injection, Bot, Brute Force, Infiltration, Exploits, Fuzzers, Backdoor, Generic, MITM, Ransomware, Theft, Analysis, Shellcode, Worms.

TABLE III
DETAILED DIVISION OF INCREMENTAL TASKS FOR iNF-UQ-NIDS-v2

iNF-UQ-NIDS-v2				
Class ID	Class	Incremental Task		
		$T = 10$	$T = 5$	$T = 2$
1	Benign	$t = 1$	$t = 1$	$t = 1$
2	DDoS			
3	DoS			
4	Scanning	$t = 2$	$t = 2$	
5	Reconnaissance			
6	XSS	$t = 3$		
7	Password	$t = 4$		
8	Injection			
9	Bot	$t = 5$	$t = 3$	
10	Brute Force			
11	Infiltration	$t = 6$		$t = 2$ (Last)
12	Exploits	$t = 4$		
13	Fuzzers			
14	Backdoor			
15	Generic			
16	MITM			
17	Ransomware	$t = 8$	$t = 5$ (Last)	
18	Theft			
19	Analysis	$t = 9$		
20	Shellcode			
21	Worms	$t = 10$ (Last)		

Dataset

- NF-ToN-IoT-v2: ~16.9 triệu bản ghi, 9 loại tấn công: Scanning, XSS, DDoS, Password, DoS, Injection, Backdoor, MITM, Ransomware

TABLE II
DETAILED DIVISION OF INCREMENTAL TASKS FOR iNF-TO N-IoT-v2

iNF-ToN-IoT-v2			
Class ID	Class	Incremental Task	
		$T = 5$	$T = 2$
1	Benign Scanning	$t = 1$	$t = 1$
2			
3			
4		$t = 2$	$t = 2$ (Last)
5		$t = 3$	
6	Password DoS		
7		$t = 4$	
8			
9	Injection Backdoor		
10	MITM Ransomware	$t = 5$ (Last)	

Data Processing

Trước khi đưa vào huấn luyện cho các bộ dữ liệu chuẩn (NF-ToN-IoT-v2 và NF-UQ-NIDS-v2), quy trình tiền xử lý được thực hiện qua các bước nghiêm ngặt sau:

- Lấy mẫu giảm thiểu (Downsampling):

Do tính chất phân bố không đồng đều giữa các lớp dữ liệu, hệ thống thực hiện downsampling để cân bằng dữ liệu:

Với NF-ToN-IoT-v2: Lấy mẫu ngẫu nhiên một nửa dữ liệu từ các danh mục có ID lớp từ 1 đến 7.

Với NF-UQ-NIDS-v2: Lấy mẫu ngẫu nhiên 1/8 dữ liệu từ các danh mục có ID lớp từ 1 đến 3, và 1/3 dữ liệu từ các danh mục có ID lớp từ 4 đến 8.

- Làm sạch và Mã hóa:


Thực hiện mã hóa nhãn (Label encoding) cho các lớp tấn công và loại bỏ các dòng dữ liệu dư thừa.

- Phân chia và chuẩn hóa:

Dữ liệu sau khi xử lý được chia ngẫu nhiên thành 40% làm tập kiểm tra (testing) và 60% làm tập huấn luyện (training).


Data Distribution

- Thiết kế quá trình huấn luyện, mô phỏng quá trình học tĩnh tiến của bài (T=5) cho dataset NF-ToN-IoT-v2: Chia làm 5 task, 1 task 2 class



Data Distribution

- Thiết kế quá trình huấn luyện, mô phỏng quá trình học tĩnh tiến của bài (T=5) cho dataset NF-UQ-NIDS-v2: Chia làm 5 task, task 1 gồm 5 class, 4 task sau 4 class



Đánh giá

Đánh giá kết quả:

- Hiệu năng: Phương pháp HFIN vượt qua các phương pháp cơ sở (baselines) khoảng 10% về độ chính xác (Accuracy) và F1-score.
- Khả năng thích ứng: Mô hình duy trì khả năng phát hiện tốt đối với cả các cuộc tấn công cũ và mới trong kịch bản tấn công-phòng thủ liên tục biến động.
- Tối ưu hóa: Chiến lược WTO giúp cân bằng hiệu quả giữa khả năng phát hiện và giới hạn tài nguyên của thiết bị biên.



Các thuật toán so sánh:

- iCaRL (2017): Học tăng trưởng lớp và phân loại mẫu.
- WA (2020): Weight Aligning để duy trì sự công bằng giữa lớp cũ và mới.
- DER (2021): Dynamically Expandable Representation.

Kết quả thực nghiệm

Cấu hình mô hình	Nguồn dữ liệu	T0 (Task 1)	T1 (Task 2)	T2 (Task 3)	T3 (Task 4)	T4 (Task 5)	Avg
iCaRL+HFL	Kết quả thực tế	95.87	76.1	63.27	59.54	60.26	71.01
	Bài báo gốc	96.1	84	56.2	74.6	75.1	77.2
iCaRL+HFL+WTO	Kết quả thực tế	95.92	72.34	62	65.09	64.96	72.06
	Bài báo gốc	96.3	92.2	74	80.8	73.2	83.3
WA+HFL	Kết quả thực tế	95.87	76.1	62.51	56.02	55.39	69.18
	Bài báo gốc	96.1	78.2	56.6	65.5	75.5	74.4
WA+HFL+WTO	Kết quả thực tế	95.92	72.34	63.74	61.87	61.28	71.03
	Bài báo gốc	96.3	92.4	76.3	81.2	78.7	85
DER+HFL	Kết quả thực tế	95.99	64.94	48.59	42.07	41.96	58.71
	Bài báo gốc	96.3	79.9	68.6	83	86.2	82.8
DER+HFL+WTO	Kết quả thực tế	89.74	67.63	56.68	55.77	52.02	64.37
	Bài báo gốc	96.2	91.9	75.8	83.1	87.4	86.9

Kết quả thực nghiệm





NF-UQ-NIDS-v2

Kết quả thực nghiệm

Cấu hình mô hình	Nguồn dữ liệu	T0 (Task 1)	T1 (Task 2)	T2 (Task 3)	T3 (Task 4)	T4 (Task 5)	Avg
iCaRL+HFL	Kết quả thực tế	96.98	70.26	56.3	47.08	58.92	66.35
	Bài báo gốc	98	94.2	74.5	54.6	57.2	75.7
iCaRL+HFL+WTO	Kết quả thực tế	97.15	72.31	55.6	46.37	55.2	64.88
	Bài báo gốc	97.6	97.8	93.2	78.7	68	87
WA+HFL	Kết quả thực tế	97.63	70.54	58.11	49.51	54.82	66.12
	Bài báo gốc	98	93.1	75.7	60.6	56.8	77.2
WA+HFL+WTO	Kết quả thực tế	96.74	80.34	56.15	47.62	57.99	67.77
	Bài báo gốc	97.6	97.8	93.7	82.3	73.4	89
DER+HFL	Kết quả thực tế	95.67	702.75	49.55	36.09	45.12	59.83
	Bài báo gốc	97.9	94.2	77.4	61.1	66.4	79.4
DER+HFL+WTO	Kết quả thực tế	96.39	70.26	54.09	44.26	48.39	62.65
	Bài báo gốc	97.8	98	95.5	82.6	68.9	88.5

Kết quả thực nghiệm



NF-ToN-IoT-v2

Tài liệu tham khảo

- [1] J. Mao, Z. Wei, B. Li, R. Zhang, và L. Song, "Toward Ever-Evolution Network Threats: A Hierarchical Federated Class-Incremental Learning Approach for Network Intrusion Detection in IIoT," IEEE Internet of Things Journal, vol. 11, no. 18, pp. 29864-29875, Sept. 2024.
- [2] X. Xu, X. Zhang, Q. Zhang, Y. Wang, B. Adebisi, T. Ohtsuki, H. Sari, và G. Gui, "Advancing Malware Detection in Network Traffic With Self-Paced Class Incremental Learning," IEEE Internet of Things Journal, vol. 11, no. 12, pp. 21816-21829, June 2024.
- [3] S.-A. Rebuffi, A. Kolesnikov, G. Sperl, và C. H. Lampert, "iCaRL: Incremental classifier and representation learning," trong Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 2001-2010.
- [4] P. Buzzega, M. Boschini, A. Porrello, D. Abati, và S. Calderara, "Dark experience for general continual learning: A strong, simple baseline," trong Advances in Neural Information Processing Systems (NeurIPS), vol. 33, pp. 15920-15930, 2020.



THANKS

DO YOU HAVE ANY QUESTIONS?

